


Previsione dei Prezzi delle Case

Dataset Ames Housing — spiegazione passo-passo, in parole semplici

Come un insieme di dati grezzi su quasi 3.000 case viene trasformato, passo dopo passo, in un sistema capace di stimarne il prezzo. Questo documento accompagna il codice e spiega ogni fase senza tecnicismi: e' pensato per essere compreso anche da chi non programma.

Fase 5 — Quanto e' accurato il modello sul test



Risultato finale: il modello stima il prezzo con un errore medio di circa il 6-7%.

Di cosa si tratta

Abbiamo a disposizione i dati di quasi 3.000 case vendute ad Ames, una città dell'Iowa (USA). Per ogni casa conosciamo decine di caratteristiche — superficie, qualità dei materiali, quartiere, anno di costruzione, presenza di garage, e così via — insieme al prezzo a cui è stata venduta.

L'obiettivo è costruire un **sistema che stimi il prezzo di una casa** a partire dalle sue caratteristiche. Il lavoro è diviso in sei fasi, come una catena di montaggio che parte dai dati grezzi e arriva a previsioni affidabili. Una regola ha guidato tutto il progetto: **non barare mai**, cioè non lasciare che il sistema 'sbirci' i dati su cui verrà giudicato.


In breve: 6 fasi, dai dati grezzi alle previsioni, con l'ossessione di non falsare i risultati.

Fase 1 — Caricare e capire i dati

Per prima cosa carichiamo i dati e li conosciamo. Ogni riga è una casa, ogni colonna una caratteristica (82 in tutto). Guardiamo come si distribuiscono i prezzi: la maggior parte delle case costa cifre 'normali', ma alcune sono molto costose e 'allungano' il grafico verso destra (immagine a sinistra).


Per rendere i dati più equilibrati e più facili da trattare, applichiamo una **trasformazione logaritmica**: comprime la coda dei prezzi alti e rende la distribuzione bella simmetrica, a campana (immagine a destra). È un trucco standard che aiuta il modello a imparare meglio.

Fase 1 — La distribuzione dei prezzi e perché usare il log



A sinistra i prezzi grezzi (sbilanciati verso destra); a destra dopo la trasformazione logaritmica (simmetrici).

Controlliamo anche le **informazioni mancanti**: alcune colonne hanno celle vuote o la sigla 'NA', che spesso significa semplicemente 'caratteristica assente' (nessuna piscina, nessun vicolo, nessun seminterrato).




Le colonne con piu' valori mancanti: quasi sempre indicano l'assenza di quella caratteristica.

In breve: Conosciamo i dati, trasformiamo i prezzi per renderli equilibrati e individuiamo le informazioni mancanti.

Fase 2 — Pulire i dati

I dati reali sono sempre un po' disordinati. Qui risolviamo due problemi. **Primo, i valori mancanti:** li riempiamo con buon senso. Quando 'NA' vuol dire 'caratteristica assente', mettiamo zero o la categoria 'Nessuno' (per esempio nessun garage = 0 posti auto). Quando invece un numero manca davvero, usiamo il valore tipico di case simili (ad esempio la dimensione media del fronte stradale nello stesso quartiere).

Secondo, gli outlier: un piccolo gruppo di case e' enorme ma venduta a poco — probabilmente vendite particolari (tra familiari, o case non finite). Questi 5 casi anomali (punti rossi nel grafico) confonderebbero il modello, quindi li togliamo.



I 5 outlier rimossi: case molto grandi vendute a un prezzo sproporzionatamente basso.

Un dettaglio cruciale per non barare: tutti questi 'valori tipici' vengono calcolati **solo sui dati di allenamento**, senza mai guardare i dati che useremo per il giudizio finale. Altrimenti il sistema avrebbe un vantaggio sleale e i risultati sarebbero falsati.


In breve: Riempiamo i buchi con buon senso e togliamo i casi anomali, imparando tutto solo dai dati di allenamento.

Fase 3 — Preparare e arricchire le caratteristiche

Il modello capisce solo numeri, quindi traduciamo ogni caratteristica in forma numerica scegliendo il metodo giusto. Le **valutazioni di qualità** hanno un ordine naturale (Scarso < Discreto < Buono < Ottimo): le trasformiamo in una scala da 0 a 5. Le **categorie senza ordine** (quartiere, tipo di tetto) diventano tante caselle 'si'/'no', una per ogni opzione.

I numeri su scale molto diverse (metri quadri contro numero di stanze) vengono **uniformati**, così nessuno domina sugli altri solo perché ha valori più grandi. Infine **creiamo nuove caratteristiche più intelligenti**: l'età della casa, la superficie totale, il numero totale di bagni, un punteggio di qualità complessivo — le stesse cose che un esperto guarderebbe d'istinto.

Fase 3 — Il preprocessing trasforma e arricchisce i dati




Le 79 colonne iniziali diventano 213 feature pronte; a destra, come vengono trattati i diversi tipi di variabile.

In breve: Traduciamo tutto in numeri nel modo giusto e aggiungiamo caratteristiche nuove e utili, passando da 79 a 213 informazioni.

Fase 4 — Costruire e confrontare i modelli

Ora addestriamo i veri motori di previsione e li confrontiamo in modo equo. Ne proviamo quattro: un **modello lineare semplice** (il riferimento di base), la sua **versione 'regolarizzata'** piu' robusta (Ridge), una **Random Forest** (tanti alberi decisionali che votano insieme) e **XGBoost** (un metodo avanzato di 'boosting').

Ogni modello viene messo alla prova con la **convalida incrociata**: dividiamo i dati di allenamento in 5 parti, alleniamo su 4 e verifichiamo sulla parte lasciata fuori, a rotazione. Così otteniamo una stima onesta di quanto il modello funzioni su dati nuovi. Regoliamo anche le impostazioni interne di ciascun modello per spremere il meglio.



Errore di ciascun modello (piu' basso e' meglio): vince il modello lineare regolarizzato, con XGBoost subito dietro.


Un risultato interessante: grazie al buon lavoro di preparazione della Fase 3, il **modello lineare regolarizzato risulta il migliore** — semplice, veloce e facile da spiegare.

In breve: Confrontiamo quattro modelli con un metodo equo e onesto; vince quello lineare regolarizzato.

Fase 5 — Verdetto finale e interpretazione

Infine misuriamo il modello scelto su un gruppo di case **mai viste prima** (il 'test'), per un giudizio onesto. Nel grafico a sinistra confrontiamo prezzo previsto e prezzo reale: i punti vicini alla diagonale indicano previsioni accurate. A destra vediamo gli errori: sono centrati intorno allo zero e simmetrici, segno che il modello non sbaglia sempre nella stessa direzione.


Fase 5 — Quanto e' accurato il modello sul test



Previsioni accurate (punti sulla diagonale) ed errori equilibrati intorno allo zero.

In numeri: il modello sbaglia in media di circa **\$11.700 (il 6,4%)**, su un prezzo tipico di ~\$183.000. Ci chiediamo anche **quali caratteristiche contano di piu'**: superficie abitabile, qualita' complessiva, dimensione del seminterrato, anno di costruzione, quartiere — esattamente cio' che guarderebbe un perito immobiliare. Il fatto che il modello dia importanza alle cose 'giuste' e' molto rassicurante.

Fase 5 — Cosa conta di piu' per il prezzo (top 10)




Le caratteristiche piu' importanti per la stima del prezzo: coincidono con l'intuizione di un esperto.

In breve: Sul test il modello e' accurato (~6% di errore) e si basa sulle caratteristiche giuste.

Fase 6 — Usarlo nella pratica

Un modello e' utile solo se si puo' davvero usare. Abbiamo quindi racchiuso tutto in una semplice funzione, **predict_price**: le si forniscono alcune caratteristiche di una casa e restituisce il prezzo stimato, completando da sola le informazioni non specificate con valori tipici.



Tre esempi: una casa grande e di qualita', una media, e una piccola e vecchia.

Abbiamo anche **salvato il modello addestrato in un file**, cosi puo' essere ricaricato e usato in seguito senza doverlo riaddestrare: e' esattamente il modo in cui un modello viene 'messo in produzione'. Il tutto e' **riproducibile**: rilanciando il codice si ottengono sempre gli stessi risultati.

In breve: Una funzione pronta all'uso stima il prezzo da poche informazioni; il modello e' salvabile, ricaricabile e riproducibile.

In conclusione

Partendo da dati grezzi e disordinati siamo arrivati a un sistema che stima il prezzo di una casa con un errore medio del 6-7%. Ogni passaggio — pulizia, preparazione, scelta del modello — e' stato fatto con una regola ferrea: **imparare solo dai dati di allenamento e toccare i dati di test una sola volta, alla fine**. E' proprio questo che rende la stima dell'errore affidabile anche su case nuove, mai viste prima.